3D-IC の熱管理における高速解析モデルを用いた構造最適化の手法検討

大屋 蒼真

2025 年 2 月

電気情報工学科

指導教員　小野 謙二

概要

目次

第 1 章　序論 1

1.1　研究の背景 1

1.2　研究の目的 1

1.3　本論文の構成 2

第 2 章　従来研究の分析と課題 3

2.1　3D-IC の構造最適化の現状と課題 3

第 3 章　熱解析の基礎方程式と各種条件 5

3.1　基礎方程式 5

3.2　離散化手法 6

3.3　解析モデル 7

3.4　境界条件 8

3.5　物性値の設定 9

第 4 章　ROM の構築 11

4.1　スナップショット 11

4.2　次元低減手法の比較 12

4.3　累積エネルギー寄与率（RIC）による基底数の決定 13

4.4　モーダル係数の予測手法 14

4.5　ROM の更新 15

第 5 章　オンライン計算 17

5.1　パラメータ探索手法 17

5.2　LLM-GA 18

5.3　評価関数と最適解の決定 19

5.4　外挿検知と ROM 更新 19

5.5　誤差判定に基づく FVM の実行と ROM 更新 20

5.6　ワークフロー 20

第 6 章　考察：提案手法の期待される効果と実現性 22

6.1 計算効率向上に関する理論的考察 22
6.2 最適化精度と汎用性についての議論 22

第 7 章 結論 23
7.1 本研究のまとめ 23
7.2 今後の課題と展望 23

参考文献 25

図目次

3.1 xy 平面断面図 7
3.2 yz 平面断面図 8

表目次

3.1　100 °C における各材質の物性値（出典：[13][14][15]）　. 9

第 1 章

序論

1.1　研究の背景

現代社会において身の回りにあふれるスマートフォン、車、家電などの電子機器の多くには半導体が搭載されており、もはや半導体なしでは現代社会は成り立たなくなっている。特に情報機器に使われる集積回路（IC）などのロジカル半導体については、長らくムーアの法則によって牽引されてきた微細化によって、近年まで目覚ましい性能向上を遂げていた。しかし、微細化のスケールが原子レベルに近づくにつれ、トンネル効果をはじめとする量子力学的制約や、露光技術の物理的限界により、従来の平面的なスケーリングによる進化は終焉を迎えつつある。このような背景から、次世代の集積技術として、チップを垂直方向に積層する 3 次元集積回路（3D-IC）が注目されている。3D-IC は、チップ間を Through-Silicon Via（TSV）等の垂直配線で接続することにより、配線長の短縮と実装面積の劇的な削減を可能にする。しかし、積層化に伴う実装密度の向上は、単位体積あたりの発熱密度の増大という深刻な熱問題を招いている。半導体素子におけるジュール熱の蓄積は、動作速度の低下やリーク電流の増大を引き起こすだけでなく、IC の許容動作温度（一般に 70°C から 100°C 程度）を超過し、物理的な破損や熱暴走を誘発する恐れがある。特に 3D-IC においては、積層構造内部の熱が外部へ逃げにくい性質を持ち、従来の空冷技術のみでは熱管理が極めて困難である。さらに、異種材料間の熱膨張係数の差に起因する熱応力は、TSV 周辺のクラックや剥離といった構造的欠陥を招く。したがって、3D-IC の実用化に向けては、最高温度の抑制のみならず、温度分布に起因する信頼性評価を含めた多角的な熱設計最適化が喫緊の課題となっている。

1.2　研究の目的

半導体製品の開発プロセスは多岐にわたり、設計の進行度に応じて要求されるシミュレーションの性質が変化する。開発後期においては詳細な解析に基づく最終確認が行われるが、製品の付加価値を決定づけ、開発効率を左右するのは設計初期段階における意思決定（フロントローディング）である。しかし、設計初期段階では、各部品の配置や構造パラメータ（層の厚さ、物性値、発熱量）が未確定であり、設計空間を網羅的に探索する必要がある。この段階で有限体積法（FVM）等のフルオーダーモデル（FOM）による高精度解析を繰り返すことは、膨大な計算時間を要するため現実的ではない。本研究の目的は、設計初期段階において、設計者が入力する制約条件に基づき、大まかな

配置構造を高速かつ自動的に最適化・予測する技術を検討することにある。これにより、3D-IC の熱設計における試行錯誤コストの削減と、開発期間の短縮に貢献するシステムの開発につなげる。

1.3　本論文の構成

第 2 章

従来研究の分析と課題

2.1　3D-IC の構造最適化の現状と課題

IC のさらなる高集積化を実現するため、3D-IC の設計開発が盛んに行われている。しかし、積層化に伴う熱密度の増大は集積化における大きな障壁となっており、この問題を解決するために、デバイスの構造的側面から放熱効率を最大化する様々なアプローチが試みられている。

3D-IC は、その構造特性上、2D-IC と比較して熱が内部に蓄積されやすいことが指摘されている [8]。特に、層間を電気的に接続する Through-Silicon Via（TSV）やはんだバンプは、同時に垂直方向の主要な熱伝導経路（サーマルビア）としても機能するため、これらの配置や密度はチップ全体の温度分布に極めて大きな影響を与える [9]。そのため、効果的な熱管理を実現するには、TSV 配置や層構造を対象とした高度な構造最適化が必要不可欠であり、本研究ではこの構造最適化による熱問題の解決を目指す。

これまでの研究では、複雑な設計空間から最適解を導出するために、生物の進化プロセスを模した遺伝的アルゴリズム（GA）[1] や粒子群最適化（PSO）[2] などの進化計算や、共分散行列の学習により実数値最適化を行う CMA-ES[3] などの、様々な手法によって設計パラメータ探索と最適化が行われてきた。しかし、3D-IC の精密な熱評価には有限体積法（FVM）等の計算負荷の高い数値解析が必要であり、最適化プロセスにおける膨大な試行に対して、これらの高精度解析を何度も実行することは、計算時間の観点から現実的ではない。

この計算コスト削減に向けた取り組みとして、いくつかの有力なアプローチが提案されている。一つは、解析モデルを簡略化した熱抵抗ネットワークモデルを用いる手法である [5]。また、設計領域内の材料分布を直接最適化するトポロジー最適化を熱問題に適用する試みもなされている [4]。しかし、熱抵抗ネットワークは計算が高速である反面、局所的な温度分布（ホットスポット）の再現性に課題があり、トポロジー最適化は設計自由度が高い一方で、3D-IC のような多層かつ異種材料が混在する複雑な境界条件の下では、収束性や製造制約の考慮が困難になる場合が多い。

これに対して有力な代替手法として広く検討されているのが、次数低減モデル（Reduced-Order Model, ROM）の活用である [6]。ROM は、事前に収集した高精度解析データ（スナップショット）に基づき、低次元基底で構成される近似空間上で温度場を評価する。これにより、FVM と同等の物理的妥当性を保持しつつ、計算負荷を劇的に低減できるという利点がある。本研究において ROM アプローチを採用する理由は、この「高精度」と「低コスト」の両立が、繰り返しの試行を要する構造

最適化において極めて有効だからである。

しかし、これらの方針においても依然として以下の課題が残っている。

第一に、ROM 構築における効率性の課題である。精度の高い ROM を構築するには、設計空間を適切に代表するスナップショットの収集が不可欠である。しかし、探索すべきパラメータ範囲が広大かつ複雑な場合、どのデータ点が精度向上に寄与するかを事前に判断することは困難であり、結果としてスナップショット生成のための膨大な事前計算がボトルネックとなる。

第二に、パラメータ探索手法そのものの非効率性である。従来の最適化手法は、あくまで数値的・統計的な試行錯誤に依存しており、「熱源の近傍に高熱伝導体（TSV）を配置すべきである」といった物理的な因果関係や設計者の知識を探索に直接反映することができない。そのため、物理的に明らかに不適切な個体を多数評価してしまい、収束までに多大な時間を要するという課題がある。

本研究ではこれらの問題を基に、3D-IC の構造最適化において適切な手法を比較検討していく。

第 3 章

熱解析の基礎方程式と各種条件

3.1 基礎方程式

熱の移動は温度勾配によって生じ、その移動量は以下のフーリエの法則（3.1）によって記述される。

$$q = -\lambda \nabla T \tag{3.1}$$

ここで、q は単位面積・単位時間あたりの熱移動量である熱流束 [W/m^2]、λ は熱伝導率 [W/(m·K)]、T は温度 [K] を表す。

物質中における伝熱形態は、固体中を伝わる熱伝導と、固体と液体の界面での熱移動である熱伝達と、電磁波等によって熱が伝わる熱輻射の 3 つの形態に大別される。まず、熱伝導方程式は熱流束およびエネルギー保存則によって記述される。微小空間において、単位時間あたりに外部から流入する熱量と内部で発生する熱量の和は、外部へ流出する熱量と内部エネルギーの変化量の和に等しい。密度を ρ [kg/m^3]、比熱を c [J/(kg·K)]、単位体積あたりの発熱量を Q [W/m^3] とすると、一般的な熱伝導方程式は式（3.2）で示される。

$$\rho c \frac{\partial T}{\partial t} = \nabla \cdot (\lambda \nabla T) + Q \tag{3.2}$$

熱伝導率 λ に関して、一般的な熱伝導問題としては温度 T の関数となるため非線形問題であり、また熱が伝わる方向によって熱伝導率が変化する異方性がある。特に半導体モデルでは、配線や絶縁層の配置と多層性に起因して面内方向と縦方向に異なる熱伝導特性が現れるため、本研究ではそれぞれの方向に異なる熱伝導率を与えて考える。

よって、式（3.2）を 3 次元直交座標について展開すると、次のように表される。

$$\rho c_p \frac{\partial T}{\partial t} = \frac{\partial}{\partial x}\left(\lambda_x \frac{\partial T}{\partial x}\right) + \frac{\partial}{\partial y}\left(\lambda_y \frac{\partial T}{\partial y}\right) + \frac{\partial}{\partial z}\left(\lambda_z \frac{\partial T}{\partial z}\right) + Q \tag{3.3}$$

次に、熱伝達について述べる。熱伝達は、固体表面の熱伝導と流体による輸送（対流）が複合した現象である。重力の影響下で高温部付近の流体が浮力により上昇する現象を自然対流と呼び、外部からのファン等の動力によって強制的に流体を動かす現象を強制対流と呼ぶ。本研究で使用するモデルのヒートシンクは、強制対流による冷却を想定している。固体表面から流体へ輸送される熱流束 q は、ニュートンの冷却法則に基づき、以下の式（3.4）で定義される。

$$q = h(T - T_\infty) \tag{3.4}$$

ここで、h は熱伝達係数 [W/(m^2·K)]、T_s は固体表面温度、T_f は流体の代表温度である。

また、熱の移動は物質を媒介しない空間においても発生する。電磁波や光がエネルギーを輸送し、熱を伝える現象を熱放射と呼ぶ。熱放射による熱流束の大きさは、次式（3.5）のように表される。

$$q = \epsilon \sigma T^4 \tag{3.5}$$

ただし、ϵ は輻射率、σ $[W/(m^2K^4)]$ はステファン-ボルツマン定数である。輻射率は $0 \leq \epsilon \leq 1$ の範囲を取り、理想的な放射体である黒体に比べて物体がどれくらいエネルギーを放出するかを表す。本研究の解析モデルにおいては、熱伝導および熱伝達による熱移動の寄与が支配的である。そのため、熱放射による影響については無視できるものと判断し、考慮しない。

3.2　離散化手法

本研究では、空間離散化手法として有限体積法（Finite Volume Method, FVM）を用いる。FVM は流体解析や熱伝導解析において広く採用されている数値解法であり、各計算セルにおいて積分型の保存則が厳密に満足される点が大きな特長である。本手法では、計算領域をコントロールボリューム（CV）と呼ばれる微小体積に分割し、各 CV に対して定義された積分型のエネルギー保存則を評価することで、領域全体での物理的な保存性を担保する。3 次元空間におけるあるセル P とその隣接セル（East, West, North, South, Top, Bottom）において、セル界面を通過する熱流束を考える。フーリエの法則に基づき、セル P から各隣接セル $nb \in \{E, W, N, S, T, B\}$ へ流出する熱量は、各界面での熱流束 q_{nb} と界面の面積 A_{nb} を用いて次式（3.6）のように一般化して表される。

$$A_{nb} q_{nb} = k_{nb}(T_P - T_{nb}) \tag{3.6}$$

ただし、q_{nb} はセル P から流出する方向が正である。また、熱コンダクタンス D_{nb} は各材料の熱伝導率 λ と格子間距離 δ を用いた調和平均により算出する。例えば、x 方向の隣接セル E との間の係数 D_e は次式（3.7）のように定義される。

$$D_e = A_e \left[\frac{\delta x_e}{\lambda_{x,e}} + \frac{\delta x_P}{\lambda_{x,P}} \right]^{-1} \tag{3.7}$$

ここで、δx はセルの中心から境界面までの距離を表す。y 方向（S, N）および z 方向（B, T）についても同様に表せる。

各界面における熱流束の総和とセル内の発熱量 Q_P との平衡を考えると、CV における熱収支式は次のように記述される。

$$\sum_{nb} (A_{nb} q_{nb}) = Q_P \Delta V_P \tag{3.8}$$

ここで、ΔV はセルの体積を表す。式 (3.6) を代入して整理すると、最終的に次式（3.9）に示す温度に関する線形離散化式が得られる。

$$a_P T_P = \sum_{nb} a_{nb} T_{nb} + b_p \begin{cases} a_P & = \sum_{nb} a_{nb} \\ a_{nb} & = D_{nb} \\ b_p & = Q_P \Delta V_P \end{cases} \tag{3.9}$$

全格子点においてこの関係式を構成することで、全体系の行列方程式 $\mathbf{AT} = \mathbf{b}$ を導出し、一般的な反復法として広く利用されている Gauss-Seidel 法と CG 法によって解く。

3.3　解析モデル

本解析で用いる 3D-IC モデル（図 3.1、3.2）の構造について述べる。本モデルは、3 層のシリコンチップ（Silicon Die）とチップ間を充填するアンダーフィル樹脂（Underfill）による積層構造を基本としている。最上面には放熱を担うヒートシンク（Heatsink）が配置され、最下面にはプリント配線基板（PCB substrate）が接合されている。各シリコンチップ層を垂直方向に貫通し、層間の電気的・熱的接続を確保するように TSV（Through-Silicon Via）が配置される。各チップ層の TSV 間は、はんだバンプ（Solder Bump）によって物理的に接続される構成となっている。各部品は単純な直方体、球体、円柱によるプリミティブ表現で構成され、その形状データは、形状タイプと座標と大きさによる最低限の量のパラメータで表現される。これによって、座標や半径といった数値を変更するだけでプログラム上でのモデルを即座に再構成したり、TSV 同士の距離制限やチップ範囲などの物理的制約を単純な数式として記述でき、最適化のパラメータとして利用しやすくなる。

本モデルでの格子の取り方について述べる。本モデルの大きさは 1.2mm × 1.2mm × 0.6mm であり、各方向について 240 × 240 × 31 個の格子に分割する。xy 平面に関しては等間隔に格子が作られるが、Z 方向の格子分割については各層の境界付近のみに格子の境界を集中させた不等間隔格子を用いる。これは、積層構造を有する 3D-IC では、Z 方向の温度分布は各層の内部では概ね線形に変化するという特性に基づいている [12]。これにより、格子数と計算コストの大幅な削減を実現している。

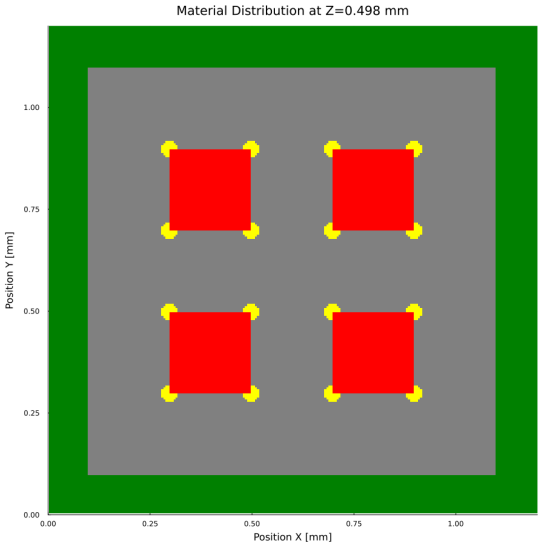

図 3.1　xy 平面断面図

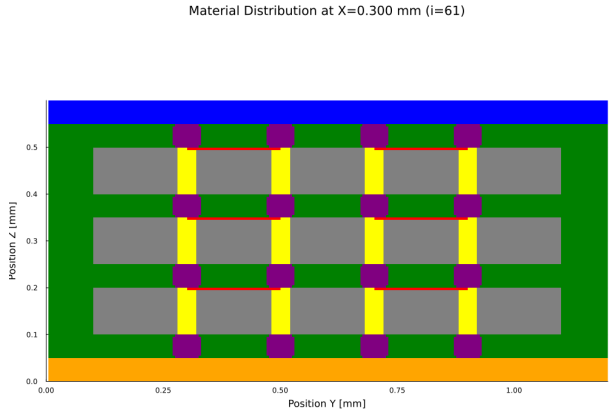

図 3.2　yz 平面断面図

3.4　境界条件

解析モデルの各表面には、物理的な環境を反映した境界条件が課される。熱伝導問題において一般的に用いられる 3 種類の境界条件を以下に述べる。

ディリクレ条件（第一種境界条件）　ディリクレ条件は、境界上の温度が直接指定される条件である。境界温度を T_{surf}、境界に隣接するセル中心の温度を T_P、セル中心から境界までの距離を d とすると、境界を介して流入する熱流束 q_s は次式（3.10）のように表される。

$$q_{surf} = \lambda \frac{T_{surf} - T_P}{d} \tag{3.10}$$

熱流束の収支とエネルギー保存則を考慮すると、境界セルにおける離散化方程式は式（3.9）を基に、境界からの寄与をソース項 b_P および係数 a_P に組み込むことで次式（3.11）のように与えられる。

$$(a_P + a_{surf})T_P = \sum_{nb} a_{nb}T_{nb} + b_P + a_{surf}T_{surf}, \quad a_{surf} = \frac{\lambda A_{surf}}{d} \tag{3.11}$$

ノイマン条件（第二種境界条件）　ノイマン条件は、境界を通過する熱流束が指定される条件である。境界から流入する熱流束を q_{surf} と置くと、境界セルにおけるエネルギー収支式は式（3.9）より次式（3.12）のように表される。

$$a_P T_P = \sum_{nb} a_{nb}T_{nb} + b_P + q_{surf}A_{surf} \tag{3.12}$$

ここで、A_{surf} は境界表面の断面積である。特に $q_s = 0$ の場合は断熱条件を意味し、境界からの熱流入・流出がないものとして扱われる。

ロビン条件（第三種境界条件）　ロビン条件は対流境界条件とも呼ばれ、境界表面における熱対流による熱流束が、表面温度 T_w と周囲の流体温度 T_∞ の差に基づいて決定される。熱伝達係数

を h とすると、周囲流体から境界に流入する熱流束 q_{surf} はニュートンの冷却法則により次式（3.13）のように表される。

$$q_{surf} = h(T_{surf} - T_{\infty}) \tag{3.13}$$

また、境界からセル P に流入する熱流束 q_{surf} を次のように表す。

$$q_{surf} = \frac{\lambda}{d}(T_P - T_{surf}) \tag{3.14}$$

この 2 つの式から未知数 T_{surf} を消去すると次式（3.15）が導かれる。

$$q_{surf} = (\frac{d}{\lambda} + \frac{1}{h})^{-1}(T_P - T_{\infty}) \tag{3.15}$$

境界に隣接するセル P における離散化方程式は式（3.9）を用いて次式（3.16）のようになる。

$$(a_P + a_{conv})T_P = \sum_{nb} a_{nb}T_{nb} + b_P + a_{conv}T_{\infty} \tag{3.16}$$

ここで、合成係数 a_{conv} は式（3.15）より、表面断面積 A_s を用いて次式で与えられる。

$$a_{conv} = A_s \left(\frac{d}{\lambda} + \frac{1}{h}\right)^{-1} \tag{3.17}$$

本モデルの上部に位置するヒートシンク表面では、冷却ファンによる強制対流によって放熱が行われる。したがって、流体への熱伝達を考慮し、ロビン境界条件を適用する。

一方、モデル下部の PCB 基板（Substrate）下面は、筐体や接地部を通じて熱が十分に逃げ、一定の温度が維持されるものと仮定する。そのため、環境温度 T_{env} を固定値として与えるディリクレ境界条件を適用する。

3.5　物性値の設定

表 3.1　100 °C における各材質の物性値（出典：[13][14][15]）

材質	熱伝導率 λ [W/(m·K)]	密度 ρ [kg/m^3]	比熱 c [J/(kg·K)]	図中での色
シリコン (Si)	103	2329	758	灰色
銅 (Cu)	393	8930	397	黄色
ハンダ (Sn-Ag-Cu)	56	7380	232	紫色
エポキシ樹脂	1.5	2500	1100	緑色
PCB 基盤（平面方向）	1.05	1850	1000	橙色
PCB 基盤（垂直方向）	0.34	-	-	-
ヒートシンク（A1060）	236	2700	942	青色

まず、シリコン基板の熱伝導率については、強い温度依存性を有することが知られている [15]。IC チップの一般的な動作温度を考慮し、本モデルでは 100°　C（373.15 K）における値である 103

W/(m·K) を採用した。これにより、常温時よりも熱抵抗が増大する実運用環境下での放熱特性をより正確に評価することが可能となる。TSV を構成する銅は、結晶構造上は多結晶体であり、マクロな視点では等方性材料として振る舞う。3D-IC における TSV の製造法は電解めっきによるものであり、めっきの成長方向とその垂直方向で極めて僅かな物性の差異が生じる可能性はあるが、3D-IC 全体の熱輸送に与える影響は支配的ではない。したがって、文献 [14] に基づき、本研究では TSV を等方性材料としてモデル化した。一方で、プリント配線基板（PCB）材料である FR-4 は、ガラス繊維織物とエポキシ樹脂から成る複合構造に起因して、強い熱的異方性を示す。具体的には、ガラス繊維の配向に沿った面内方向（x, y 方向）に比べ、樹脂層を横切る面直方向（z 方向）の熱伝導率が著しく低下する。本解析では、この異方性が全体の温度分布に与える影響を考慮するため、文献 [14] で示されている方向別の熱伝導率をそれぞれ個別に設定した。

第 4 章

ROM の構築

3D-IC の構造最適化問題においては、広大なパラメータ空間を探索するために膨大な回数の数値計算が必要となる。これら全てのケースに対して有限体積法（FVM）を適用することは、高精度な解析を可能にする一方で、極めて大きな計算コストを要し、現実的な時間内での最適化を困難にする。これに対し、次数低減モデル（Reduced Order Model, ROM）は、フルオーダーモデルから温度場の支配的な空間基底を抽出することで、物理的特徴を保持したまま、極めて少ない次元数で温度場を近似することができる。

4.1 スナップショット

ROM を構築するためには、まず設計空間からサンプリングされた各パラメータ点において、FVM による詳細な解析を実行し、基礎となる温度場データセット（スナップショット）を収集する必要がある。

ある s 番目（$s = 1, \ldots, S$）のスナップショットにおける各設計パラメータ μ_i（$i = 1, \ldots, P$）をまとめて設計パラメータベクトルとして次式で表す。

$$\boldsymbol{\mu}^{(s)} = (\mu_1^{(s)}, \mu_2^{(s)}, \ldots, \mu_P^{(s)}) \tag{4.1}$$

これを用いてある設計パラメータベクトル $\boldsymbol{\mu}^{(s)}$ における温度場ベクトルを次のように表す。

$$\boldsymbol{T}(\mathbf{x}; \boldsymbol{\mu}^{(s)}) \tag{4.2}$$

なお、$\mathbf{x}$ は全計算格子（M 個）における位置情報を表すパラメータである。このスナップショットを設計パラメータごとに並べて行列表記したものはスナップショット行列と呼ばれ、次式（4.3）で表される。

$$\mathbf{S} = [\boldsymbol{T}(\mathbf{x}; \boldsymbol{\mu}^{(1)}), \boldsymbol{T}(\mathbf{x}; \boldsymbol{\mu}^{(2)}), \ldots, \boldsymbol{T}(\mathbf{x}; \boldsymbol{\mu}^{(S)})] \in \mathbb{R}^{M \times S} \tag{4.3}$$

ただし、なお、本研究では全スナップショットから求めた平均温度場との差を実際の計算に用いる。平均温度場と実際に用いるスナップショット行列は次式（4.4）（4.5）（4.6）のように表される。

$$\bar{\boldsymbol{T}}(\mathbf{x}) = \frac{1}{S} \sum_{k=1}^{S} \boldsymbol{T}(\mathbf{x}; \boldsymbol{\mu}^{(k)}) \tag{4.4}$$

$$\tilde{\mathbf{S}} = [\boldsymbol{T}(\mathbf{x};\boldsymbol{\mu}^{(1)}) - \bar{\boldsymbol{T}}(\mathbf{x}), \boldsymbol{T}(\mathbf{x};\boldsymbol{\mu}^{(2)}) - \bar{\boldsymbol{T}}(\mathbf{x}), \ldots, \boldsymbol{T}(\mathbf{x};\boldsymbol{\mu}^{(S)}) - \bar{\boldsymbol{T}}(\mathbf{x})] \tag{4.5}$$

$$= [\tilde{\boldsymbol{T}}(\mathbf{x};\boldsymbol{\mu}^{(1)}); \tilde{\boldsymbol{T}}(\mathbf{x};\boldsymbol{\mu}^{(2)}), \ldots, \tilde{\boldsymbol{T}}(\mathbf{x};\boldsymbol{\mu}^{(S)})] \tag{4.6}$$

この操作により、定数的な温度上昇成分が除外され、構造や熱源配置の変化に起因する空間的な温度分布の変動に焦点を当てることが可能となる。これは、主要な特徴を少数のモードに集約させる（低ランク近似を容易にする）だけでなく、熱伝導が温度勾配によって発生するという物理的側面にも則っている。

スナップショットに用いるパラメータの決定方法として、ラテン超格子（Laten HyperGrid Sampling, LHS）を用いる [19]。この手法では、多次元空間においてサンプル点が均一に散らばるように各パラメータを選択できるサンプリング手法である。単なるランダム生成（モンテカルロ法）では空間に偏りができる可能性があるが、LHS では多次元空間を効率的かつ均一に表現することができる。具体的には、設計空間の各次元を N 等分し、各層から重複が発生しないように一つずつサンプルを選択する。これによってどのパラメータ軸に投影しても、サンプルが重ならず均等に配置され、最小限のスナップショット数で設計空間全体を表現できる。

各設計パラメータは独立で、次のような範囲を取るとする。

$$\mu_i \in [\mu_i^{min}, \mu_i^{max}] \tag{4.7}$$

このパラメータ範囲を S 個の等確率区間に分割し、次のように表す。

$$[\mu_i^{min}, \mu_i^{max}] = \bigcup_{k=1}^{S} I_{i,k} \tag{4.8}$$

なお、I は分割された部分集合を表す。これを用いて、ある設計パラメータ μ_i に関して、s 番目に生成されるパラメータ $\mu_i^{(s)} \in I_{i,\pi_{i(s)}}$ は次の式で表される。

$$\mu_i^{(s)} = \mu_i^{min} + (\frac{\pi_i(s) - 1 + \xi_{i,s}}{S})(\mu_i^{max} - \mu_i^{min}) \tag{4.9}$$

ただし、π_i は $\{1, \ldots, S\}$ の任意の置換であり、$\xi_{i,s}$ は [0,1] の値をとる区間内乱数である。

4.2　次元低減手法の比較

ROM の構築において極めて重要な過程である次元低減には、複数のアプローチが存在する。本節では、熱伝導問題の解析において広く用いられる 2 つの代表的な手法について比較検討を行う。

固有直交分解（POD）　固有直交分解（Proper Orthogonal Decomposition, POD）は、スナップショット行列に対して特異値分解（Singular Value Decomposition, SVD）を適用し、抽出された空間基底を用いる手法である。スナップショット行列 $\mathbf{X} \in \mathbb{R}^{M \times S}$ の SVD は次のように定義される。

$$\mathbf{X} = \mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^T \tag{4.10}$$

ここで、$\mathbf{U} \in \mathbb{R}^{M \times M}$ および $\mathbf{V} \in \mathbb{R}^{N \times N}$ は直交行列であり、$\boldsymbol{\Sigma} \in \mathbb{R}^{M \times S}$ は対角成分に特異値 σ_i を持つ対角行列である。SVD によって得られた空間基底（左特異ベクトル）のうち、特

異値の大きい順に r 本の基底を選択することで、低次元空間を構成する基底ベクトル群が得られる。特異値の大きさは、その基底が空間全体の変動を表現する際の「寄与度」に対応しており、上位のモードほど支配的な物理現象を表している。こうして構築される低次元空間は、最小二乗誤差の意味において元の空間を最も適切に近似する基底であることが、Eckart–Young の定理によって数学的に保証されている。

テンソルトレイン（TT）分解　一方、テンソルトレイン（Tensor Train, TT）分解は、スナップショットデータを多次元配列（高階テンソル） $\mathcal{A} \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d}$ として扱い、この配列を複数のテンソルコアの積によって近似する手法である [20]。

TT 分解は次式で表される。

$$\mathcal{A}(i_1, i_2, \ldots, i_d) \approx \mathbf{G}_1(i_1)\mathbf{G}_2(i_2)\ldots\mathbf{G}_d(i_d) \tag{4.11}$$

TT 分解の主な特徴は、空間方向ごとの多次元構造を保持したまま圧縮が可能であり、変数の増加に伴う計算コストの爆発、いわゆる「次元の呪い」を効果的に回避できる点にある。しかし、POD と比較して、抽出されたコアから物理的な空間モードを直接的に解釈することが困難であるという側面を持つ。

本研究では以下の理由から POD を採用する。

1. **物理的解釈性**: POD 基底は空間的な温度分布パターンとして視覚化が可能であり、物理的特徴を捉えやすい。
2. **拡張性**: 最適化の過程で外挿領域や誤差の大きな領域が検知された際、新規スナップショットを既存の行列に追加して再構築を行う適応的更新が容易である。
3. **実装の容易性**: TT 分解と比較して、SVD に基づくアルゴリズムは汎用ライブラリが非常に充実しており、確実な実装が可能である。
4. **計算規模の妥当性**: 本研究で扱う設計パラメータの数（300 サンプル程度）は、POD において次元の呪いが致命的となるほど高次元ではない。

4.3　累積エネルギー寄与率（RIC）による基底数の決定

SVD によって抽出された空間基底から低次元基底を構成する際、近似空間の次元数（ランク）r を適切に決定することが極めて重要である。基底数 r が過小な場合は、温度場の主要な物理的特徴を十分に表現できず近似精度が低下する。一方で、r が過大な場合は、計算コストが増大するだけでなく、数値誤差や微細なノイズまで学習（過学習）してしまい、未知のパラメータに対する汎化性能を損なう恐れがある。本研究では、統計的な寄与度に基づき適切な r を決定する手法として、累積エネルギー寄与率（Relative Information Content, RIC）を用いる。SVD により得られる特異値行列の対角成分である特異値 σ_i は、各モードが温度分布の変動（エネルギー）を保持する強度を表している。全エネルギーに対する第 r 基底までの累積エネルギー寄与率 $E(r)$ は、次式で定義される。

$$E(r) = \frac{\sum_{i=1}^{r} \sigma_i^2}{\sum_{j=1}^{k} \sigma_j^2} \tag{4.12}$$

ここで、k はスナップショット行列のランク（最大サンプリング数）である。適切な閾値 η（例えば 0.999 など）を設定し、$E(r) \geq \eta$ を満たす最小の r を基底数として採用する。フルオーダーモデル（FOM）における自由度が数千から数万以上に及ぶのに対し、熱伝導問題では r が数十程度の極めて低い次元で支配的な温度場を表現可能であり、ROM による空間近似の極めて高い有用性が示唆される。

4.4　モーダル係数の予測手法

実際に近似された解空間を表現するには、解空間の主要なモードを表す POD 基底の線形結合で表現する必要がある。スナップショット行列から SVD によって抽出された POD 基底を次式で表す。

$$\mathbf{\Phi} = [\phi_1, \phi_2, \ldots, \phi_r] \in \mathbb{R}^{M \times r} \tag{4.13}$$

この POD 基底を用いて、任意の設計パラメータベクトル $\boldsymbol{\mu}_i$ における低次元温度場は次式で表される。

$$\begin{aligned} \boldsymbol{T}(\mathbf{x}; \boldsymbol{\mu}_i) &\simeq \mathbf{\Phi}\boldsymbol{a}(\mu_i) && (4.14) \\ &= a_1(\boldsymbol{\mu}_i)\phi_1 + a_2(\boldsymbol{\mu}_i)\phi_2 + \cdots + a_r(\boldsymbol{\mu}_i)\phi_r && (4.15) \end{aligned}$$

$$\boldsymbol{a}(\mu) = [a_1(\mu), \ldots, a_r(\mu)]^T \in \mathbb{R}^{r \times 1} \tag{4.16}$$

式（4.16）はモーダル係数ベクトルと呼ばれ、任意の設計パラメータに対する温度場の予測のためには、パラメータ $\boldsymbol{\mu}_i$ とモーダル係数行列 $\boldsymbol{a}(\boldsymbol{\mu}_i)$ の対応関係（写像）を明らかにする必要がある。すなわち、ROM 構築の際に得られたスナップショットの情報を利用し、$\mu \mapsto a$ という未知の写像を学習・予測するモデルを構築する。本研究では、この写像の近似手法として放射基底関数（Radial Basis Function, RBF）を用いる [17]。RBF は、各データ点 μ_j を中心とした多次元空間上の距離に基づき補間を行う手法であり、高次元パラメータ空間に散在する非構造的なデータ群に対しても、非常に滑らかかつ高精度な補間が可能であるという特長を持つ。

まず、既知の各スナップショット $\boldsymbol{\mu}^{(s)}$ について、FVM で得た解を POD 行列基底に射影し、射影ベクトル $\mathbf{a}^{(s)}$ を得る式を示す。

$$\begin{aligned} \mathbf{a}^{(s)} &= \mathbf{\Phi}^T \mathbf{T}^{(s)} && (4.17) \\ &= [a_1^{(s)}, a_2^{(s)}, \ldots, a_r^{(s)}]^T && (4.18) \end{aligned}$$

RBF モデル構築の流れでは、射影ベクトル $\mathbf{a}^{(s)}$ は既知のモーダル係数ベクトルモーダル係数 $\boldsymbol{a}(\boldsymbol{\mu})$ として扱われる。第 i モーダル係数 $a_i(\mu)$ の予測式は、次式（4.19）のように表される。

$$a_i(\boldsymbol{\mu}) = \sum_{j=1}^{S} w_{ij}\phi(\|\mu - \mu_j\|) \tag{4.19}$$

ここで、ϕ はカーネル関数、$\|\cdot\|$ はノルム、w_{ij} は学習によって決定される重み係数、S はサンプリング数、μ_j は既知のデータ点である。

重み係数の学習は次の連立一次方程式（4.20）を解くことによって得られる。

$$\begin{bmatrix} a_i(\mu_1) \\ \vdots \\ a_i(\mu_S) \end{bmatrix} = \begin{bmatrix} \phi(\|\mu_1 - \mu_1\|) & \dots & \phi(\|\mu_1 - \mu_S\|) \\ \vdots & \ddots & \vdots \\ \phi(\|\mu_S - \mu_1\|) & \dots & \phi(\|\mu_S - \mu_S\|) \end{bmatrix} \begin{bmatrix} w_{i1} \\ \vdots \\ w_{iS} \end{bmatrix} \tag{4.20}$$

また、カーネル関数には様々な関数が用いられるが、本研究ではガウス関数を用いる。距離 $r = \|\mu - \mu_j\|$ とすると、カーネル関数 $\phi(r)$ を次式（4.21）のように表す。

$$\phi(r) = \exp(-\frac{r^2}{2\sigma^2}) \tag{4.21}$$

標準偏差 σ についても様々な決定法がある。理想的な場合ではこの σ についても逐次最適化をするのが適切であるが、RBF モデル最適化のために FOM を行うのは計算コストが大きいことに加えて、外挿や ROM の誤差が大きい場合には ROM が更新されるので、本研究では平均近傍距離に基づく定数によって設定する。

全サンプルの各点から最も近い隣接点までの距離の平均 d_{avg} を基準に、標準偏差 σ を次のように定める [18]。

$$\sigma = d_{avg} \tag{4.22}$$

4.5　ROM の更新

ROM によって構成される低次元空間の近似精度は、スナップショット点の密度と、解空間の勾配に強く依存する。パラメータ探索の過程において、もし最適解が近似精度の低い領域に位置する場合、その解の妥当性を担保することが困難になる。この場合は最適化計算を中断して ROM の再構築を行う必要がある。また、スナップショットの学習で用いたパラメータ範囲の外部や、スナップショット点が疎なデータを外挿と呼ぶが、この外挿と判定されたパラメータに対しても ROM を再構築する場合がある。それぞれの判定方法については 5.4、5.5 で説明する。

ROM の更新プロセスにおいて、新たな学習点を追加するたびにスナップショット行列を再構成し、SVD を再実行する手法は、全スナップショットデータの保持が必要となり、メモリのリソースを大きく割くことになる。よって、構築された POD 基底と特異値情報のみ保持し、新しいデータを統合・拡張することで ROM を再計算する Incremental SVD（ISVD）という手法をとる [21]。

具体的な手順を次に示す。

まず、追加スナップショットを近似空間に射影し、基底に直行する残差ベクトル $\boldsymbol{r}$ を導出する。

$$\boldsymbol{r} = \{\boldsymbol{T}_{new}(\mathbf{x}; \mu_{new}) - \bar{\boldsymbol{T}}(\mathbf{x})\} - \boldsymbol{\Phi}_{old}\boldsymbol{a}(\mu_{new}) \in \mathbb{R}^M \tag{4.23}$$

新しい基底候補 $\boldsymbol{q}$ は、残差ベクトルのノルム $\rho = \|\boldsymbol{r}\|$ を用いて次式（4.24）のような正規化された残差ベクトルで表される。

$$\boldsymbol{q} = \frac{\boldsymbol{r}}{\rho} \in \mathbb{R}^M \tag{4.24}$$

また、保持していた特異値行列、追加スナップショットの射影と残差ベクトルのノルムを用いて次にように中間行列 $\mathbf{K}$ を次式（4.25）のように表す。

$$\mathbf{K} = \begin{bmatrix} \sigma_1 & 0 & \dots & 0 & a_1 \\ 0 & \sigma_2 & \dots & 0 & a_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & \sigma_r & a_r \\ 0 & 0 & \dots & 0 & \rho \end{bmatrix} \in \mathbb{R}^{(r+1)\times(r+1)} \tag{4.25}$$

この中間行列 $\mathbf{K}$ に SVD の操作を行うと次式（4.26）のようになる。

$$\mathbf{K} = \mathbf{U}'\mathbf{\Sigma}'\mathbf{V}'^T \tag{4.26}$$

この操作で求まった $\mathbf{U}'$、Φ_{old} と式（4.24）を用いて、新たな基底は次式（4.27）のように求まる。

$$\mathbf{\Phi}_{new} = [\mathbf{\Phi}_{old}|\boldsymbol{q}]\mathbf{U}' \in \mathbb{R}^{M\times(r+1)} \tag{4.27}$$

この新たな基底に対する特異値は式（4.26）の行列 $\mathbf{\Sigma}'$ の対角成分に保存されている。

第 5 章

オンライン計算

前章で述べた ROM 構築は、パラメータ探索が始まる前の事前準備であり、最適化ループとは切り離されていることからオフライン計算と呼ばれる。本章で述べるオンライン計算は、オフライン計算で得られた近似モデルを基に高速に進化計算のループを実行する工程である。ROM を導入することでパラメータ探索をするごとに FOM の計算をする手間を省き、効率的に探索を行うことができる。

本章では、まずオンライン計算で用いるパラメータ探索手法について比較検討後、決定した探索手法についての要素技術や定義を述べ、最後に全体の流れをまとめる。

5.1 パラメータ探索手法

パラメータ探索（最適化）アルゴリズムには、問題の性質に応じて多様な手法が存在する。本研究の対象である 3D-IC の熱設計最適化に適用可能な主要手法には以下のようなものがある。

- **遺伝的アルゴリズム（Genetic Algorithm, GA）**
  生物の進化過程（選択、交叉、突然変異）を模倣した確率的探索手法である。評価関数の値に基づく個体の選別と、パラメータ同士の情報の組み換えによって探索を進める。多峰性を持つ複雑な設計空間においても、局所解に陥ることなく全域的な最適解を探索できる能力に優れている。その一方で、解から離れた領域を探索することで計算時間が長くなる欠点もある。
- **ベイズ最適化（Bayesian Optimization,BO）**
  ガウス過程回帰などのサロゲートモデルを用い、未知の領域に対する期待改善量を最大化するように次の探索点を決定する手法である。高コストな評価関数に対して少ない試行回数で収束する利点があるが、パラメータの次元数が増加するにつれて代理モデルの構築コストが指数関数的に増大する課題がある。
- **遺伝的プログラミング (Genetic Programming, GP)**
  個体をビット列や数値ではなく「木構造（計算式やプログラム）」として表現し進化させる手法である。物理現象を記述する近似式の自動生成などに用いられるが、本研究のように具体的な幾何学的配置（座標や直径）を直接最適化する問題においては、解の表現が複雑になりすぎる傾向がある。
- **CMA-ES**

共分散行列適応進化戦略 (Covariance Matrix Adaptation Evolution Strategy, CMA-ES) は、探索を進めながら、評価が改善される方向の相関関係（共分散行列）を学習する。また、探索の歩幅を自動調節するので、大胆な探索と最後の微調整を両立できる。

本研究では、有限体積法（FVM）により離散化された熱伝導方程式を扱い、設計パラメータには TSV の座標や直径といった物理量が含まれ、これらは設計空間において高度に非線形な応答を示す。この前提を基に各手法を比較する。

まず、ベイズ最適化はフルオーダーモデル（FOM）のように一回の評価が極めて重い場合には有効であるが、本研究のように次数低減モデル（ROM）を用いて評価コストを劇的に低減した環境下では、代理モデル構築のオーバーヘッドがメリットを上回り、採用する意義が薄い。次に CMA-ES は、連続的な勾配情報を利用して高精度な収束を実現するが、本解析のようなメッシュ解像度に依存する系においては、メッシュ内の微小な変化に対して評価値が変化しない「不感帯」で探索が停滞し、局所解や不適切な解に収束するリスクがある。

これに対し、GA は不連続な評価関数に対してもロバストに動作するが、探索が確率的なランダム性に依存するため、物理的に無意味な領域（熱源から遠い箇所の探索など）を評価し続けるといった「探索の収束の遅さ」が最大の欠点となる。

そこで本研究では、この GA の非効率性を大規模言語モデル（LLM）の導入によって解決する手法を提案する [10]。LLM が持つ物理的なドメイン知識を探索プロセスに介入させることで、従来の数学的・確率的アプローチのみでは不可能であった「物理的意味を加味した探索誘導」を実現する。具体的には、LLM が熱分布の結果を解釈し、物理的妥当性の高い方向へ突然変異や初期集団の生成を誘導することで、探索空間を効果的に絞り込む。

5.2　LLM-GA

本研究では、大規模言語モデル（LLM）の物理的な知識による推論能力を進化計算（GA）の各オペレーターに統合した「LLM-GA」の構築を提案する。先行研究 [10] によれば、LLM は複雑な構造を持つ組合せ最適化問題において、単なる解の生成器としてだけでなく、進化的オペレーターとして機能し、問題の制約を遵守しながら解を反復的に改善する能力を持つことが示されている。

- **交叉**
  交叉工程では、優れた評価を持つ親個体群のパラメータセットを LLM に入力する。LLM は親個体間の共通点や相違点を抽出し、それらを論理的に結合することで、単なる統計的な組み合わせ（平均値や一点交叉など）では到達しにくい、物理的な因果関係を維持した子個体を生成する。
- **適応的変異**
  変異は解の多様性を維持するために不可欠であるが、完全なランダム変異は収束を妨げる。本手法では、LLM が現在の解において排熱が滞っている領域を特定し、その近傍へ優先的に TSV を再配置する「適応的変異」を導入する。LLM が現状の解における温度分布を解釈し、排熱が滞っているホットスポット領域を特定する。特定された領域の近傍へ優先的に TSV を

再配置、あるいは直径を調整するよう LLM が指示を生成する。これにより、従来のガウス変異と比較して、物理的妥当性の高い探索空間への集中が可能となる。

- **選択**
  選択工程では、目的関数の評価値に加え、LLM による解の背後にある構造的な妥当性や論理的な整合性の評価を補助的に用いる。特に、熱的な改善が頭打ちになった際、LLM が進化的プロセスにおける解の停滞を検知し、多様性を促す個体を戦略的に次世代へ残すことで、局所解からの脱却を図る。
- **エラー修正機構** LLM の出力には稀に制約条件（TSV 同士の干渉やチップ範囲外への配置など）を無視したり、フォーマット上のエラーを起こす不確実性が含まれる。そこで、先行研究 [10] の知見に基づき、LLM の出力後に物理的制約を確認する検証層を設け、制約違反がある場合には自動的にパラメータを修正する機構を実装する。これにより、LLM の柔軟な探索能力と、工学的な厳密性を両立させる。

次に、本研究で用いる各手法の説明と定義を行う。

5.3　評価関数と最適解の決定

ROM によって算出された近似温度場 $T_{ROM}(\mathbf{x}, \mu)$ を、設計目的に基づいて定量的指標で評価する。IC の正常な動作を保証する観点からはチップ内の最大温度が、また熱応力による構造破損を抑制する観点からは最大温度勾配や熱源間の温度差などが評価項目として挙げられる。また、電気的な遅延を減らすために TSV の配線長を最小化することも多い。

本研究では、提案手法の基本的な妥当性を検証するため、チップ全体の最大温度を単一の対物指標として用いることを提案する。評価関数 $f(\mu)$ は次式で定義される。

$$f(\mu) = \max_{\mathbf{x} \in \Omega} T_{ROM}(\mathbf{x}, \mu) \tag{5.1}$$

ここで、Ω は解析対象とする 3D-IC の全領域を指す。最適化のプロセスにおいては、この評価関数 $f(\mu)$ を最小化する設計パラメータ μ の探索を目的とする。

最適解の決定方法として、最良固体が一定世代（ストール世代数）更新されない場合と、改善幅の閾値が小さい場合に進化計算を停止をする条件を設け、進化計算が停止した段階での最優良固体を最適解として決定する [22]。ストール世代数については全体の世代数の 10 20% の世代数、改善幅の閾値については目的関数の 10^{-4}〜10^{-6} 程度を目安とする。

5.4　外挿検知と ROM 更新

既存のスナップショット群が覆う凸包（Convex Hull）の外部や、サンプル点が極めて疎な領域を「外挿領域」と呼ぶ。この範囲では ROM の精度が保証されないので、外挿となったパラメータに対して FOM の計算を行い、ROM を更新する必要がある。ROM 更新の方法については 4.5 で述べた。

本研究では、LHS のサンプリング密度に基づき外挿判定を行う [23]。

具体的には、判定する新たなパラメータ $\boldsymbol{\mu}^{(*)}$ と、その最も近くにある既知のスナップショット点 $\boldsymbol{\mu}^{(j)}$ との距離 $d(\mu^*)$ を用いる。パラメータ空間での各次元はスケールが異なるので、各パラメータ

を正規化する。

あるパラメータの正規化を次式（5.2）で表す。

$$\mu_i' = \frac{\mu_i - \mu_i^{min}}{\mu_i^{max} - \mu_i^{min}} \tag{5.2}$$

この操作を各次元について施すと、距離 $d(\mu^*)$ は次式で表される。

$$d(\mu^{(*)}) = \min_{j=1,\ldots,N} |\mu'^{(*)} - \mu'^{(j)}| \tag{5.3}$$

算出された最小距離 $d(\mu^{(*)})$ があらかじめ設定された閾値 d_{crit} を上回る場合、当該パラメータを外挿と判定する。初期スナップショット群において、各点から最も近い点までの距離（の平均 d_{avg} を計算し、その 1.5 倍〜2.0 倍 程度を d_{crit} と設定する。外挿と判定されたパラメータに関しては、直ちに FVM による高精度解析を実行し、得られた結果を新たなスナップショットとして行列 $\mathbf{S}$ に追加する。その後、SVD による基底の再抽出および RBF モデルの再学習を行うことで、ROM の空間表現能力を動的に拡張する。

5.5　誤差判定に基づく FVM の実行と ROM 更新

最適化プロセスにおいて評価関数に基づき「有望」と判断された個体（エリート個体等）については、その信頼性を担保するために FVM による検証を行い、誤差が大きい場合は ROM 更新を行う。ROM 更新の手法については 4.5 で述べた。ROM による予測温度場 $\mathbf{T}_{ROM}$ と、FVM による厳密解 $\mathbf{T}_{FVM}$ との誤差を評価し、近似モデルの妥当性を確認する。誤差の指標として、本研究では以下の最大絶対誤差を用いる。

$$\epsilon_{max} = \max_{k=1,\ldots,M} |T_{ROM,k} - T_{FVM,k}| \tag{5.4}$$

算出された誤差 ϵ_{max} が許容値 ϵ_{tol} 以下であれば、当該パラメータにおける ROM の予測は十分に信頼できるものと判断し、探索を継続する。一方で、誤差が許容値を超える場合は、現在の ROM の空間表現能力が当該領域において不十分であると見なし、得られた FVM 結果をスナップショット行列に追加して ROM を再構築する。この逐次更新プロセスにより、最適解近傍におけるモデル精度を重点的に向上させることが可能となる。

5.6　ワークフロー

最後に、本研究で提案するオンライン計算のワークフローを次に示す。

1. **パラメータの生成**
   遺伝的アルゴリズム（GA）に基づき、現世代の個体群（設計変数 μ の集合）を生成する。
2. **外挿検知および適応的更新**
   生成されたパラメータが、既存のスナップショット群が構成する凸包（Convex Hull）の外側、すなわち ROM の精度が保証されない「外挿領域」にあるか否かを判定する。外挿と判定された場合には、直ちに FVM を実行し、得られた結果をスナップショット行列に追加して ROM を再構築（更新）する。

3. **ROM による高速評価**
   ROM を用いて各個体の温度場を瞬時に予測し、5.3 の評価関数を基にパラメータを評価する。
4. **FVM による誤差検証と逐次更新**
   最適化プロセスにおいて有望と判断された個体に対し、検証用の FVM を実行する。ROM による予測値と FVM による厳密値の誤差が許容値 ϵ を超える場合、当該サンプルをスナップショットに追加し、POD 基底とモーダル係数の再計算を行うことでモデルの再構築を行う。
5. **次世代の生成**
   評価結果に基づき、交叉・突然変異を経て次世代のパラメータ群を生成する。以上のプロセスを 5.3 で示す収束条件を満たすまで繰り返す。

第 6 章

考察：提案手法の期待される効果と実現性

6.1　計算効率向上に関する理論的考察

6.2　最適化精度と汎用性についての議論

第 7 章

結論

7.1　本研究のまとめ

7.2　今後の課題と展望

謝辞

参考文献

[1] John H. Holland: Adaptation in Natural and Artificial Systems, MIT Press, 1992.

[2] J. Kennedy and R. Eberhart: Particle swarm optimization, roceedings of ICNN'95 - International Conference on Neural Networks, pp. 1942-1948, 1995.

[3] Nikolaus Hansen and Andreas Ostermeier: Completely Derandomized Self-Adaptation in Evolution Strategies, Evolutionary Computation, vol. 9, no. 2, pp. 159-195, 2001.

[4] Joe Alexandersen and Ole Sigmund and Boyan S. Lazarov: Topology optimisation of passive coolers for light-emitting diode lamps, Applied Thermal Engineering, vol. 72, pp. 103-114, 2014.

[5] W. Huang, S. Ghosh, et al: HotSpot: A compact thermal modeling methodology for early-stage VLSI design, IEEE Transactions on Very Large Scale Integration (VLSI) Systems, vol. 14, no. 5, pp. 501-513, 2006.

[6] Matthew J. Zahr, Charbel Farhat: Progressive construction of a parametric reduced-order model for PDE-constrained optimization, arXiv:1407.7618, 2014.

[7] Fatemeh Tavakkoli, Siavash Ebrahimi, Shujuan Wang, Kambiz Vafai：Analysis of critical thermal issues in 3D integrated circuits、https://doi.org/10.1016/j.ijheatmasstransfer.2016.02.010, 2016.

[8] Sungjun Im and Kaustav Banerjee:Full chip thermal analysis of planar (2-D) and vertically integrated (3-D) high performance ICs, 10.1109/IEDM.2000.904421, 2000.

[9] C. K. Patra et al:Analysis of critical thermal issues in 3D integrated circuits, 10.1007/978-0-387-76534-1-14, 2009.

[10] Jie Zhao, Tao Wen, Kang Hao Cheong: Can Large Language Models Be Trusted as Evolutionary Optimizers for Network-Structured Combinatorial Problems?,arXiv:2501.15081, 2025.

[11] Yuxin Qian, Cong Hao, Takeshi Yoshimura: 3D-IC Signal TSV Assignment for Thermal and Wirelength Optimization, 10.1109/PATMOS.2017.8106948, 2017.

[12] Kenji Ono, Takahiro Iwasaki, Takeshi Ohkawa: High-Throughput Thermal Simulation for Early-Stage 3D-IC Design Using Automated Meshing and Pseudo-3D Modeling, 10.1109/IMPACT67645.2025.11281775, 2025.

[13] Y. S. Touloukian et al:Thermophysical Properties of Matter - Vol. 1 (Thermal Conductivity), Vol. 4 (Specific Heat), Plenum, 1970.

[14] J. H. Lau: Three-Dimensional IC Packaging, McGraw-Hill, 2011.

[15] C. J. Glassbrenner and Glen A. Slack: Thermal Conductivity of Silicon and Germanium from 3K to the Melting Point, Physical Review, vol. 134, no. 4A, pp. 10.1103/PhysRev.134.A1058, 1964.

[16] I. V. Oseledets: Tensor-train decomposition, https://doi.org/10.1137/090752286, 2011.

[17] Xiao. D et al: Non-intrusive reduced order modelling of the Navier-Stokes equations, Computer Methods in Applied Mechanics and Engineering, 293, 522-541, https://doi.org/10.1016/J.CMA.2015.05.015, 2015.

[18] Franke. R: Scattered data interpolation: Tests of some methods,Vol. 38, No. 157 (Jan., 1982), pp. 181-200 (20 pages), https://www.jstor.org/stable/2007474, 1982.

[19] M. D. McKay, R. J. Beckman, W. J. Conover: A Comparison of Three Methods for Selecting Values of Input Variables in the Analysis of Output from a Computer Code, https://doi.org/10.2307/1268522, 1979.

[20] I. V. Oseledets: Tensor-train decomposition, https://doi.org/10.1137/090752286, 2011.

[21] Matthew Brand:Incremental singular value decomposition of uncertain data with missing values,10.1007/3-540-47969-4-47,2002.

[22] Marcin Studniarski: Stopping Criteria for Genetic Algorithms with Application to Multiobjective Optimization, Parallel Problem Solving from Nature, PPSN XI ,pp 697–706 , 2010.

[23] Alexander I. J. Forrester and Andy J. Keane: Recent advances in surrogate-based optimization, DOI:10.1016/J.PAEROSCI.2008.11.001, 2008.